RELATÓRIO EXERCÍCIO TÉCNICO - FOOTBALL ANALYTICS



Introdução

A proposta do desafio passava pela exploração de dados de futebol, tomando o repositório público da StatsBomb como base para extração e transformação de dados, com vista à criação de métricas valiosas e visualizações espelhando as mesmas, permitindo a retirada de conclusões relevantes acerca da performance dos jogadores e equipas em questão.

Desenvolvimento

Escolha do Jogo

Comecei por escolher, entre os dados disponíveis, qual o jogo mais adequado para partir para análise.

Escolhi a final do UEFA Euro 2024, onde a Espanha se superiorizou à Inglaterra (2-1), pela dimensão do jogo em questão, mas principalmente por ter curiosidade em explorar mais acerca da equipa espanhola e do estilo de jogo em posse que tem por base. Achei que seriam uma boa base de exploração e criação de métricas. E o jogo cumpria os requisitos propostos (incluir dados 360).

Primeiro passo

Ao saber já à partida que iria trabalhar em Python e, como tal, instalar bibliotecas necessárias, comecei por utilizar a boa prática de criar um ambiente Virtual (.venv) para ter um ambiente isolado e instalar as dependências necessárias no mesmo.

No ambiente Windows, utilizei os comandos:

```
python -m venv .venv
.venv\Scripts\Activate.ps1
```

E de seguida, criei um requirements.txt onde fui colocando as bibliotecas necessárias.

Extração dos Dados Necessários

Numa primeira fase, através da estrutura do repositório era possível fazer download apenas dos JSONs necessários, pois através dos Identificadores da Competição e da Época presentes no competitions.json foi possível perceber onde estava o jogo em questão na pasta matches, e consequentemente, ir buscar o match_id que permitia encontrar a informação da pasta events, lineups e three-sixty, apenas do jogo desejado.

A estrutura do Repositório:

data/competitions.json — lista de todas as competições/épocas (1 ficheiro pequeno, 80 registos)

data/matches/{competition_id}/{season_id}.json — jogos de cada competição, com metadados ricos (equipas, datas, fase, jornada, etc.)

data/events/{match_id}.json — os eventos (ficheiros pesados)

data/lineups/{match_id}.json — 11 iniciais

data/three-sixty/{match_id}.json — os frames 360 (os mais pesados de todos)

Foi ao perceber esta estrutura que comecei por criar uma camada de extração inteligente dos dados, onde foi possível escolher qualquer qualquer jogo para mais tarde analisar, sem ter que clonar todo o repositório. Escolhendo a competição, a época e posteriormente o jogo em questão, a camada é estruturada para ir buscar os ficheiros ao repositório correspondentes a esse jogo (extract.py). Deste modo é possível a análise de todos os jogos (que incluem dados 360) sem ser necessário clonar todo o repositório.

Desta camada resulta a diretoria contendo os dados do jogo, na estrutura do repositório original.

Estruturação dos Dados JSON para DataFrames

Com os ficheiros do jogo já na diretoria, o objetivo desta camada passou por transformar os JSONs — que trazem uma estrutura encaixada (*nested*) e pouco prática de manipular — em tabelas (DataFrames) limpas e organizadas, prontas para análise. Cada um dos quatro ficheiros exigiu um tratamento próprio.

Nos **eventos** (events), que são o ficheiro central e mais complexo, recorri ao json_normalize para desdobrar os dicionários encaixados em colunas planas, identificadas com underscores (por exemplo, o tipo de evento passou a estar numa coluna type_name). De seguida, ordenei os eventos pelo campo index, garantindo que a tabela fica exatamente pela ordem temporal em que o jogo aconteceu. Por fim, como a localização de cada evento vinha guardada numa lista [x, y], extraí essas coordenadas para duas colunas próprias, deixando-as prontas para os cálculos espaciais que as métricas viriam a exigir.

Os **11 iniciais** (lineups) foram reorganizados para forma longa, ficando uma linha por jogador, com a respetiva equipa, número, posição inicial e restante informação associada.

Os **dados 360** foram os que exigiram a transformação mais cuidada. Cada registo contém um freeze_frame, que é a lista das posições de todos os jogadores no instante de um dado evento. Em vez de manter essa lista encaixada, expandi-a para forma longa, ficando com uma tabela em que cada linha corresponde a um par (evento, jogador). A visible_area — o polígono da zona que o tracking conseguiu observar — foi guardada à parte, num dicionário, precisamente por ser a mesma para todos os jogadores de um frame, não fazendo sentido repeti-la em cada linha.

A chave que liga estes dados aos eventos é a igualdade freeze.event_uuid == events.id, o que permite, sempre que necessário, cruzar cada evento com o respetivo instantâneo posicional.

Quanto aos **metadados do jogo** (matches), o tratamento consistiu em localizar o jogo em questão dentro do ficheiro da época e carregar a sua informação, estruturada de forma semelhante à descrita acima.

O resultado de toda esta camada é um único objeto, a que chamei **Jogo**, que reúne as quatro tabelas e disponibiliza ainda um conjunto de atalhos úteis para as consultar e cruzar — por exemplo, obter o freeze frame de um evento ou seguir os eventos relacionados entre si. Por fim, testei o carregamento, confirmando que os dados surgem já devidamente estruturados e prontos para a fase seguinte: a criação de métricas.

Métricas

O objetivo desta camada foi transformar os dados já estruturados em métricas de desempenho que dessem leituras concretas sobre o jogo. Desenvolvi duas, garantindo que pelo menos uma recorresse aos dados 360, conforme pedido.

A primeira — **passes que quebram linhas** — assenta precisamente nesses dados 360. Considerei que um passe quebra uma linha quando deixa adversários para trás, em direção à baliza: recorrendo ao freeze frame do instante do passe, conto quantos adversários ficam dentro do "corredor" do passe, isto é, entre o seu início e fim e suficientemente próximos da sua trajetória. Restringi a análise a passes progressivos, e o número de adversários assim ultrapassados traduz a força de cada passe. Mantive parâmetros como a largura do corredor configuráveis, para que a definição pudesse ser afinada e justificada, em vez de fixada de forma arbitrária.

Equipa	Jogador	↓ Passes que quebram linhas	Adversários quebrados (total)	Máx. num só passe
Spain	Robin Aime Robert Le Normand	17	20	2
Spain	Fabián Ruiz Peña	15	19	2
Spain	Aymeric Laporte	14	21	3
Spain	Marc Cucurella Saseta	13	16	3
Spain	Nicholas Williams Arthuer	12	25	3
Spain	Daniel Carvajal Ramos	9	15	5
England	Kyle Walker	9	15	5
Spain	Daniel Olmo Carvajal	8	16	4
Spain	Rodrigo Hernández Cascante	8	14	4

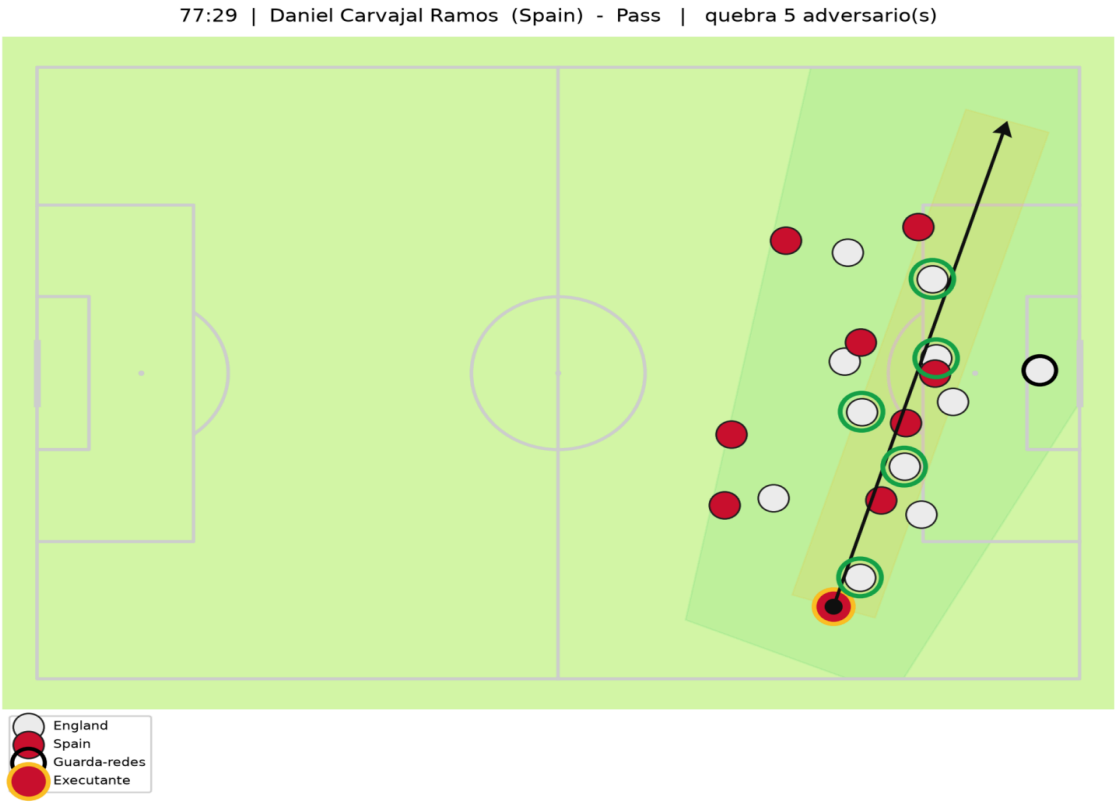
A segunda métrica nasceu de uma ideia. Ao escolher as **ações sob-pressão**, ocorreu-me analisar também os dados da pressão exercida pelo adversário a essas ações, e construir métricas que comparam a compostura dos jogadores com bola perante a pressão, e a pressão do ponto de vista defensivo, de quem pressiona. Do lado ofensivo, a métrica mede a percentagem de posse que cada jogador retém quando pressionado; do lado defensivo, quantas pressões cada um aplicou. Para ligar quem pressiona a quem é pressionado, recorri ao campo related_events, que associa cada ação de pressão à ação adversária que a sofreu.

Visualizações

O objetivo desta camada foi dar corpo visual às métricas, privilegiando representações espaciais sobre o campo de jogo — que é onde os dados 360 mais se destacam. Para desenhar os campos recorri à biblioteca mplsoccer, e mantive a lógica de separação das camadas: as funções de visualização recebem os dados já estruturados e devolvem a figura, sem calcular nada por si.

Uma decisão transversal foi a das cores das equipas. Como os dados da StatsBomb não incluem as cores dos equipamentos, optei por as tornar configuráveis e resolvidas pela equipa real — ou seja, a Espanha aparece sempre com a mesma cor, quer se esteja a observar uma ação sua ou da Inglaterra —, o que torna a leitura imediata em qualquer visualização.

A visualização base é o freeze frame: o instantâneo posicional de um evento desenhado sobre o campo, com os colegas e os adversários distinguidos pela cor, o executante da ação destacado, os guarda-redes assinalados e a área visível pelo tracking sombreada. Sobre esta base construí a visualização dos passes que quebram linhas, que acrescenta o corredor do passe e destaca os adversários ultrapassados — de modo a que a imagem mostre exatamente o que a métrica contou.



Para a pressão criei um mapa de pressão, um heatmap que revela em que zonas do campo cada equipa pressiona, com as duas equipas lado a lado e uma escala de cor partilhada, para que a comparação entre elas seja justa. Por fim, o onze inicial de cada equipa é apresentado sobre o campo, com cada jogador colocado na sua posição média real ao longo do jogo, o que dá logo à partida uma leitura do posicionamento e das intenções de cada equipa.

Uma nota importante em todas estas visualizações prende-se com a orientação das coordenadas: como a StatsBomb normaliza os dados de forma a que a equipa em posse ataque sempre no mesmo sentido, foi necessário ter esse cuidado ao representar as duas equipas no mesmo campo, invertendo as coordenadas de uma delas para que se posicionem frente a frente, como num jogo real.

Interface

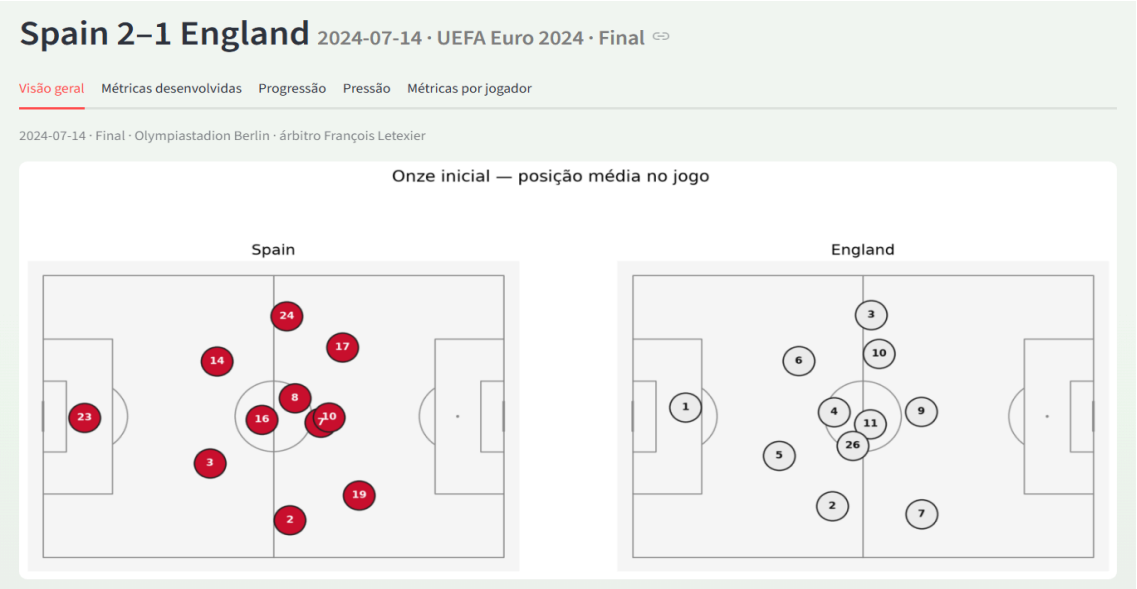
A componente visual foi construída em Streamlit, escolhida por ser a ferramenta com que tenho mais familiaridade. A aplicação funciona como uma camada fina por cima de todo o trabalho anterior: importa as camadas de extração, estruturação, métricas e visualização, limitando-se a orquestrá-las e a apresentar os resultados.

O fluxo começa numa barra lateral, onde o utilizador escolhe a competição, a época e o jogo a analisar. Só após confirmar essa escolha é que a aplicação vai buscar os dados e gera a análise, evitando processamento desnecessário. É também aqui que se ajustam as cores das equipas.

A análise em si está organizada em cinco separadores, para manter a informação limpa e navegável. A **Visão Geral** apresenta o resultado, os dados do jogo e o onze inicial de cada equipa sobre o campo. As **Métricas Desenvolvidas** reúnem as duas métricas principais e os insights que delas resultam, sustentados pelas respetivas visualizações. Seguem-se dois separadores de exploração mais aprofundada — um dedicado à **Progressão** e outro à **Pressão** —, onde é possível consultar todas as ocorrências e inspecionar cada uma individualmente. Por fim, o separador **Métricas por Jogador** permite focar a análise num jogador específico e explorar as suas ações ao longo do jogo.

Conclusões e Insights Principais

A posição média revela que o Morata desce muito para vir buscar jogo e o Dani Olmo até pisa terrenos mais ofensivos que o avançado. Do outro lado, também revela que o Luke Shaw (defesa-esquerdo) esteve mais presente no meio campo ofensivo que no defensivo.



A Espanha foi claramente superior na progressão ofensiva, liderando as estatísticas de passes que quebram linhas, confirmando assim ser uma equipa muito forte a descobrir soluções em posse. É de destacar os jogadores Nico Williams e Dani Olmo, cujos passes foram os que mais quebraram linhas adversários em relação ao número de passes efetuados por eles. De destacar os dois defesas centrais estarem no topo da lista, confirmando que a Espanha é uma equipa que privilegia a saída em posse desde a 1ª fase de construção, com defesas muito confortáveis com bola no pé.

As métricas das Ações sob pressão confirmam a principal valência desta equipa: o momento com bola. Os 89% de retenção da posse sob pressão confirmam a dificuldade do adversário em retirar a bola à Espanha, sendo a diferença de 16% para a Inglaterra um indicador claro da qualidade da Espanha com bola.

O meu destaque individual vai claramente para o **Dani Olmo**, pois além de arrasar nas métricas com posse, foi o 2º jogador que mais exerceu ações de pressão no adversário (27), o que demonstra o jogo completíssimo que fez com e sem bola.

Conclusão e Melhorias Futuras

Foi particularmente entusiasmante para mim combinar duas áreas as quais gosto tanto: Dados e Futebol.

Como melhorias futuras, veio-me à cabeça, logo no início do desenvolvimento, a aplicação de Modelos Preditivos nas ações dos jogadores. Com que objetivo? Perceber se o jogador em questão é ou não previsível na sua ação. Tendo por base várias ações com as mesmas condições, de vários jogadores em situação semelhante, se o ator da ação em questão tende a, por exemplo, fazer o passe mais comum.

De resto, melhorias de interface, como normalizar os nomes dos jogadores (no dataset aparecem os nomes completos, muitas vezes confundido acerca do jogador em questão, pois no mundo do futebol têm um nome diferente), traduzir os nomes das equipas, e no geral alargar a análise, pois havia muito mais para explorar.

Elaborado por: Rui Soares, 2026